

南京工程学院

课程设计任务书

课 程 名 称	<u>数据采集技术课程设计</u>
院（系、部、中心）	<u>计算机工程学院</u>
专 业	<u>计算机类</u>
班 级	<u>大数据241&大数据242</u>
起 止 日 期	<u>2026.06.22 ~ 2026.07.03</u>
指 导 教 师	<u>赵健</u>

一、 课程设计应达到的目的

《数据采集技术》课程设计的考核以项目为主，项目是一个完整流程的大数据采集与预处理的项目，从**数据采集、预处理、简单存储、分析到展示**，每个流程都有一定的技术挑战，其中每一环节所用到的技术都有多种选择，可根据个人偏好或熟悉程度进行选择，可选择现有的开源项目，也可自己动手写一些工具。

二、 课程设计题目及要求

完成要求：至少完成题目中所包含的需求，外加自己提出一些创新的功能，最后需要验收一个完整的分析成果，包含所有分析结果的文档、网页、图片或可运行的系统。

分组要求：可独立或自由组队完成项目，**每个小组最多 6 人**。若分组则每个人的在团队中的职责不可重复，所做的工作需在课程设计报告中体现出来，报告中注明各自的分工，如下表，同时对于自己所完成的部分，重点介绍，详细写该部分内容。

数据采集	数据分析	可视化	数据存储	数据处理	日志采集
同学 1	同学 2	同学 3	同学 4	同学 5	同学 6

同学 1	数据爬虫，构建数据分析汇总表，构建可视化图表（部分）
同学 2	搭建框架，构建可视化图表（部分），图表结果分析
同学 3	构建可视化图表（部分），图表结果分析
同学 4	数据存储，数据清洗异常值处理，图表结果分析

选题要求：**同一题目最多 2 个团队同时选择**（同一个班级内）。

技术要求：使用 **Hadoop 框架**进行项目的构建。

最终提交：

- (1) **报告一份**（主要写自己个人的工作情况，团队成员的工作可简单介绍），报告格式请参考文件“《数据采集技术》课程设计报告封面+封底.docx”；
- (2) **数据采集技术项目的完整代码**，代码必须可运行（可部分借鉴网上开源项目，但必须经过修改、改进或集成）。

提交日期：

- (1) 报告：课程设计结束后的下一周周一提交课程设计报告纸质版和电子版。电子版命名为：**学号+姓名**
- (2) 代码：课程设计结束当天，检查验收后。
(注意：每一组的报告收在一起)

三、 课程设计所需理论、技术及工具

1) 理论知识:

大数据采集技术是一个综合性理论及技术, 根据不同的项目, 所用到的技术不同, 具体可能包括: 爬虫技术、数据 ETL 技术、分布式数据库及 NoSQL 数据库、机器学习及数据挖掘、自然语言处理 (NLP)、社会网络分析、复杂网络分析、知识图谱等, 部分内容需要自学。

2) 相关工具:

数据采集: Scrapy 参考 <https://zhuanlan.zhihu.com/p/64305013>

ETL 工具: Kettle

存储: 文件、各类数据库、Hadoop HDFS、MongoDB 等

数据查询: Hive、Redis 等

数据计算: MapReduce、python 及其相关包 (pandas、numpy、requests、等等)

可视化: Excel、echart、python matplotlib 和 JavaScript 库等

具体流程主要包括:

- (1) 利用爬虫技术抓取相应网站的数据, 数据量不少于 1 万条, 并保存为 csv 文件。
- (2) 通过数据预处理将抓取下来的数据进行处理, 如: 处理缺失值、删除重复值、过滤无效数据、添加序号、对异常值进行处理、数据标准化等等。
- (3) 构建 Hadoop 服务集群, 并将预处理后的 csv 数据文件上传到 HDFS 或 MongoDB 中。
- (4) 利用 MapReduce、Hive 连接 HDFS 进行数据分析、数据挖掘的工作, 并将分析结果存入 HDFS 中。
- (5) 通过网页、可视化工具等对分析结果进行展示。

四、 课程设计题目

1. 非上市公司的数据分析

- 1) 抓取非上市公司的公开数据, 如: IT 橘子和 36Kr, 以及通过全国各省市企业信用信息公示系统获得部分公司的工商数据。
- 2) 构建类似企查查的公司基本信息查询系统。
- 3) 构建公司、股东的关联关系图, 构建成复杂网络, 并验证复杂网络特性。
- 4) 构建可视化的网站展示。

2. 大众点评、美团网等餐饮大数据分析

- 1) 收集点评数据, 可用爬虫, 或自行寻找网络公开数据集。

- 2) 展示点评数据在城市地图上的分布, 统计不同城市的平均消费水平, 包括点评数量、商家数量等。
- 3) 进一步分析数据, 包括: 城市商家数量和美食类型、人均消费、不同城市及人群的最钟爱的美食类型、人均消费和评价指数、人均消费和综合指数、口味指数和环境指数关系、评价数量和评价指数等。以及各种变化的口味, 比如: 啤酒在衰退, 重庆小面在崛起。
- 4) 构建可视化的网站展示。

3. 社交网络大数据

- 1) 抓取社交网络数据, 如: 以知乎为例。
- 2) 统计用户相关信息, 可通过分布图、柱状图、饼图等展示, 包括: 用户性别统计、职业统计、毕业学校统计、用户地区统计、用户粉丝数分布图、用户关注数分布、回答数统计、发帖数统计、僵尸用户统计 (没有任何发帖、回帖记录)。
- 3) 通过复杂网络分析, 进行关键节点挖掘 (大 V), 构建大 V 的关系网络, 验证六度人脉关系, 小世界、Scale-free 特性是否成立, 在网络中进行社区发现 (community detection)。
- 4) 汇总问题和所有的答案, 找出 20xx 年最热门和最衰落的行业。
- 5) 构建可视化的网站展示。

4. 基于大数据的电影票房预测系统

- 1) 使用爬虫在主流电影评论网站上抓取国内票房过万元的电影基本信息和评论文本;
- 2) 使用情感分析的方法计算了电影评论的情感得分, 统计不同类型电影的票房和评价的差异;
- 3) 通过多指标对影片的评价进行建模, 如: 总票房、第一周豆瓣评分、影片时长、第一周正面评论得分、第一周负面评论得分、加权后的首映周票房、总上映天数、第一周入场人数、上映第一天百度指数等;
- 4) 能通过建模的模型进行票房的预测, 可使用历史数据进行测试并计算准确率、召回率等;
- 5) 并构建可视化的网站展示。

5. 医疗信息大数据

抓取医疗问题问答, 如: 寻医问药网、好大夫在线、39 健康网等, 对大量的问答数据进行大数据分析。

- 1) 统计询问发帖时间, 如: 询问的时间都是在 21 点左右, 呈现出标准的正太分布, 20、

22 就有点显得过早、过晚。说明大家一般都是在晚上 9 点左右有时间提问，这个时间也是用户最为活跃的时间。

- 2) 建立疾病，症状，检查，药品，身体部位，感觉特征等词典库，分析相关词语的分布，如药品的分布特征，疾病的分布特征等。
- 3) 结合人群特征分析不同病的性别，年龄分布等。
- 4) 根据字典形式的数据创建结点，以疾病为中心定义关系形成三元组表示的知识，将结点和关系导入 neo4j 数据库形成知识图谱。
- 5) 构建可视化的网站展示。

6. 招聘求职大数据

- 1) 设计爬虫，对国内主流的招聘网站数据进行抓取，并进行数据预处理。
- 2) 构建一个招聘数据的搜索引擎，根据多种字段进行信息的查询。
- 3) 统计不同城市、不同行业、不同岗位的招聘数据，分析维度包括但不限于：职位热度、薪资待遇、学历要求、工作经验、地域分析、行业类型、公司类型、地区均值等。还可统计各个职位需要掌握的前 5 个或者前 10 个关键技能。互联网行业哪个职位比较有前途等。
- 4) 构建可视化的网站展示，包括：词云、地图等。

7. 汽车交易大数据

采集易车网、汽车之家等汽车网站的内容数据、评论数据等。

分析内容：关注某车型并提及相关关键词的用户、关注某车型的用户总数。

通过 NLP 技术，构建不同品牌用户的用户画像，如：

- 1) 统计基础信息，不同品牌、车型的车主性别比例，年龄分布、地区分布、车主职业分布、车颜色分布、车价格分布等。
- 2) 基于语义情感分析技术，对不同品牌、不同车型的车主对车的映像及他人对车主的映像等进行情感分析，情感分类可简单分为积极型、消极型、中性型。
- 3) 不同品牌用户的帖子文本中出现的关键词最多的，用词云展示。
- 4) 分析哪个品牌用户最注重操控性？哪个品牌用户最注重稳定性？哪个品牌用户最注重外观？哪个品牌、车型最保值？什么类型的贬值较快？一年当中买车的最佳时间为何时？等等。
- 5) 构建可视化的网站展示。

8. 旅游出行大数据

获取游记类的数据，如：马蜂窝、穷游网等，通过对游记、攻略、旅游产品数据的抓取。

- 1) 分析某一景点或旅游团产品的评论, 用词云展示, 统计热门旅游产品, 统计热门景点。
- 2) 分析不同旅游景点、旅游线路的人气、评价、价格等; 分地区对所有景点进行排序。
- 3) 根据发帖信息, 统计不同景点、城市在几年来发帖数来反应其热门程度。
- 4) 对某地区的相关内容的高频词提取、语意网络分析, 整理出食、住、行、游、购、娱旅游六要素的总体评价。
- 5) 构建可视化的网站展示。

9. 房产大数据

- 1) 设计爬虫抓取 58 同城的房产、安居客、Q 房网、搜房等房产网站, 抓取房产买卖及租售信息, 对房价问题进行分析。
- 2) 分析内容主要包括但不限于: 各城市房价趋势图、成交量趋势、城市人口密度、城市租售比、房溢价空间、户型欢迎程度、房价与股市相关性、房价分布图、房价面积分布关系图等; 然后对全国不同城市的不同指标进行排序对比。
- 3) 除了新房的分析, 另外再分析二手房的相关数据。
- 4) 构建可视化的网站展示。

10. 网路舆情大数据

采集综合论坛、新闻门户、知识问答、自媒体网站、社交平台等网络媒体上的相关舆情信息。

- 1) 文本预处理, 智能提取信息正文、标题, 自动对信息进行语义识别, 包括文本分词、去停用词、词权重计算等步骤, 并根据关键字进行分类处理。
- 2) 对热点信息进行评测, 找出关注点并记录实时舆情热点信息, 形成热点实践库。
- 3) 以文字和图表的形式直观的形式, 生成网络舆情趋势图表。
- 4) 按地区、话题、人名、站点等进行分类排序。同时可进行敏感词的匹配, 挖掘负面舆情。
- 5) 构建可视化的网站展示。

11. 自定义题目

如果有其他自己感兴趣的题目, 也可以跟我联系进行定题。类型、方向不限, 但必须能获取到数据 (可自己用爬虫抓取或在下面的数据集列中寻找), 且须用到 Hadoop 平台。

附：

开放数据集（以下为互联网公开数据集，可供下载）：

舆情监测研究的公开数据集是当前研究舆情监测的重要数据来源，包含了大量的舆情数据，为舆情监测研究提供了数据基础支撑。下面将介绍几个重要的公开数据集。

1. 知网舆情数据集：该数据集是知网公司开发的舆情监测产品，包含了大量的新闻、微博、论坛等舆情信息。该数据集提供了多维度的数据分析和可视化工具，方便用户进行舆情监测和分析。
2. 新浪微博数据集：新浪微博是中国最大的社交媒体平台之一，拥有庞大的用户基础和海量的微博数据。该数据集提供了丰富的微博内容和用户信息，可以用于研究用户行为和舆情传播规律。
3. 豆瓣电影评论数据集：豆瓣是一个电影、图书、音乐等文化产品的评价和分享平台，用户可以在该平台上发布对文化产品的评价和评论。该数据集收集了豆瓣电影评论数据，可以用于研究电影评价和口碑。
4. 新华社新闻数据集：新华社是中国最大的新闻机构，拥有全球最大的新闻网络。该数据集收集了新华社发布的新闻信息，可以用于研究新闻报道和舆情传播。

舆情监测研究的公开数据集为舆情研究提供了重要的数据基础支撑，为研究舆情传播和用户行为提供了有力的工具和资源。

社交网络、复杂网络

<http://snap.stanford.edu/data/>

https://toreopsahl.com/datasets/#online_social_network

<https://dblp.uni-trier.de/db/>

阿里天池大数据

<https://tianchi.aliyun.com/dataset/>

大数据分析处理竞赛平台

<https://www.datafountain.cn/datasets>

kaggle 数据挖掘竞赛平台

<https://www.kaggle.com/datasets>

情绪分析

多域情绪分析数据集：一个有点老旧的数据集，其中包含来自亚马逊的产品评论。

<http://www.cs.jhu.edu/~mdredze/datasets/sentiment/>

IMDB 评论：一个较旧的，相对较小的二元情绪分类数据集，包含 25,000 个电影评论。

<http://ai.stanford.edu/~amaas/data/sentiment/>

斯坦福情绪树库：带有情感注释的标准情绪数据集。

<http://nlp.stanford.edu/sentiment/code.html>

Sentiment140：一个流行的数据集，使用 160,000 条预先删除表情符号的推文。

<http://help.sentiment140.com/for-students/>

Twitter 美国航空公司情绪：2015 年 2 月美国航空公司的 Twitter 数据，分类为正面、负面和中性推文。

<https://www.kaggle.com/crowdflower/twitter-airline-sentiment>

自然语言处理

1) IMDb Large Movie Review Dataset

用于情感二元分类的数据集，其中包含 25,000 条用于训练的电影评论和 25,000 条用于测试的电影评论，这些电影评论的特点是两极分化特别明显。另外数据集里也包含未标记的数据可供使用。

引文：http://ai.stanford.edu/~amaas/papers/wvSent_acl2011.pdf

下载地址：<https://s3.amazonaws.com/fast-ai-nlp/imdb.tgz>

2) Wikitext-103

超过 1 亿个语句的数据合集，全部从维基百科的 Good 与 Featured 文章中提炼出来。广泛用于语言建模，当中包括 fastai 库和 ULMFiT 算法中经常用到的预训练模型。

引文：<https://arxiv.org/abs/1609.07843>

下载地址：<https://s3.amazonaws.com/fast-ai-nlp/wikitext-103.tgz>

3) Wikitext-2

Wikitext-103 的子集，主要用于测试小型数据集的语言模型训练效果。

引文：<https://arxiv.org/abs/1609.07843>

下载地址：<https://s3.amazonaws.com/fast-ai-nlp/wikitext-2.tgz>

（公司的数据集）安然数据集：来自安然高级管理层的电子邮件数据，以文件夹形式分类存放。

<https://www.cs.cmu.edu/~./enron/>