

南京工程学院

实 验 报 告

课 程 名 称 大数据采集技术

实验项目名称 舆情热点大数据采集

学 号 202180403

姓 名 _____

班 级 大数据

实 验 时 间 2020 年 6 月 22 日

实 验 地 点 _____

实验成绩评定 _____

指导教师签字 _____ 年 ____ 月 ____ 日

实验六 舆情热点大数据采集

一、实验目标

1. 掌握舆情热点大数据采集技术的基本理论；
2. 通过实验了解舆情热点大数据采集技术的各个环节和应用；
3. 熟悉舆情热点大数据采集技术的软件和环境搭建，并简单完成应用实例。

二、实验平台

操作系统：Ubuntu

JDK 版本：1.8

Python 版本：3.8

DataX

Kettle

MySQL

三、实验内容

主要包括：

3.1 舆情热点大数据采集技术的基本理论

3.2 实验内容：

- 1、采用爬虫技术获取舆情数据；
- 2、使用 DataX 技术导入舆情热点数据 CSV 文件到数据库；
- 3、使用 Kettle 技术对舆情热点数据进行清洗、过滤等操作；
- 4、显示真实、有效的数据。

3.1 基本理论

舆情热点大数据采集技术基本理论

1、项目目标

本项目利用爬虫技术获取各种舆情热点信息，根据关键词对它们执行清洗操作，之后再把清洗过的数据保存下来，接下来收集更多的数据，清洗新的数据并把清洗结果与前面处理完的结果数据结合起来，重新进行清洗、保存等操作，以获取更加准确、完整的舆情信息。

2、项目意义

舆情热点大数据融合平台利用大数据技术的海量数据收集、搜索、分析、处理能力解决对舆论的监测分析，其主要应用价值

如下：

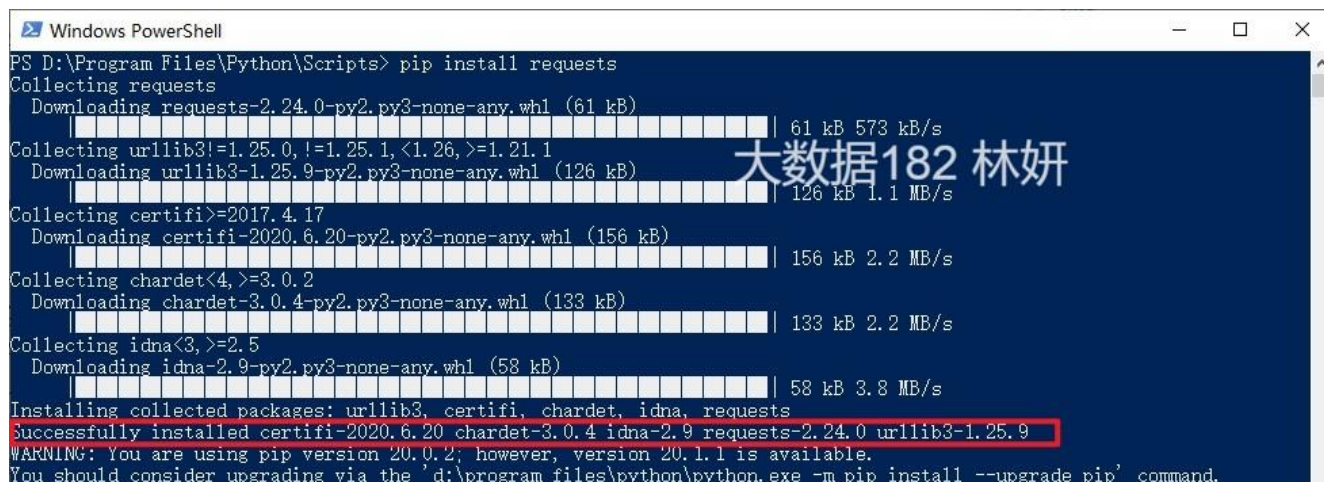
- (1) 帮助用户在海量数据中找到最有价值的舆情信息
- (2) 根据舆情影响程度进行级别分类
- (3) 保证 7×24 小时不间断实时监测
- (4) 帮助地方政府建立起一套预警机制

3.2 实验内容

一、采用爬虫技术获取舆情数据

1. 下载所需的插件 requests

pip install requests



```
Windows PowerShell
PS D:\Program Files\Python\Scripts> pip install requests
Collecting requests
  Downloading requests-2.24.0-py2.py3-none-any.whl (61 kB)
    | 61 kB 573 kB/s
Collecting urllib3[!=1.25.0,!=1.25.1,<1.26,>=1.21.1]
  Downloading urllib3-1.25.9-py2.py3-none-any.whl (126 kB)
    | 126 kB 1.1 MB/s
Collecting certifi>=2017.4.17
  Downloading certifi-2020.6.20-py2.py3-none-any.whl (156 kB)
    | 156 kB 2.2 MB/s
Collecting chardet<4,>=3.0.2
  Downloading chardet-3.0.4-py2.py3-none-any.whl (133 kB)
    | 133 kB 2.2 MB/s
Collecting idna<3,>=2.5
  Downloading idna-2.9-py2.py3-none-any.whl (58 kB)
    | 58 kB 3.8 MB/s
Installing collected packages: urllib3, certifi, chardet, idna, requests
Successfully installed certifi-2020.6.20 chardet-3.0.4 idna-2.9 requests-2.24.0 urllib3-1.25.9
WARNING: You are using pip version 20.0.2; however, version 20.1.1 is available.
You should consider upgrading via the 'd:\program files\python\python.exe -m pip install --upgrade pip' command.
```

图 1 下载 requests 插件

2. 要爬取的网站: <https://news.qq.com/zt2020/page/feiyang.htm>



图 2 需要爬取的网站数据

注：网站截图时间为 6 月 28 日，爬取的时间为 6 月 24 日，图中显示的数据略有不同

3. 编写 python 代码爬取数据

(1) 获取网页数据，并做初步处理，将各省份的现有确诊人数、累计确诊人数、现有疑似数据、累计死亡数、死亡率、累计治愈数据、治愈率、新增确诊数据，进行分离、汇总



```
import time, json, requests, re
# 抓取腾讯疫情实时 json 数据
url = 'https://view.inews.qq.com/g2/getOnsInfo?name=disease_h5&callback;=&_=%'
data = json.loads(requests.get(url=url).json()['data'])

#原始数据
num = data['areaTree'][0]['children']
for item in num:
    print(item['name'], end=" ") # 不换行
    print(item['today'])
    print(item['total'])
else:
    print("\n") # 换行

# 现有确诊数据
nowConfirm = {}
for item in num:
    nowConfirm.update({item['name']:item['total']['nowConfirm']})
print("现有确诊数据")
print(nowConfirm)

# 累计确诊数据
total_confirm = {}
for item in num:
    total_confirm.update({item['name']:item['total']['confirm']})
print("累计确诊数据")
print(total_confirm)

# 现有疑似数据
nowSuspect = {}
for item in num:
    nowSuspect.update({item['name']:item['total']['suspect']})
print("现有疑似数据")
print(nowSuspect)

# 累计死亡数据
total_dead = {}
for item in num:
    total_dead.update({item['name']:item['total']['dead']})
print("累计死亡数据")
print(total_dead)
```

图 3 爬取数据并初步处理数据（1）

```

# 累计死亡数据
total_dead = {}
for item in num:
    total_dead.update({item['name']:item['total']['dead']})
print("累计死亡数据")
print(total_dead)

# 死亡率
deadRate = {}
for item in num:
    deadRate.update({item['name']:item['total']['deadRate']})
print("死亡率")
print(deadRate)

# 累计治愈数据
total_heal = {}
for item in num:
    total_heal.update({item['name']:item['total']['heal']})
print("累计治愈数据")
print(total_heal)

# 治愈率
healRate = {}
for item in num:
    healRate.update({item['name']:item['total']['healRate']})
print("治愈率")
print(healRate)

# 新增确诊数据
new_confirm = {}
for item in num:
    new_confirm.update({item['name']:item['today']['confirm']})
print("新增确诊数据")
print(new_confirm)

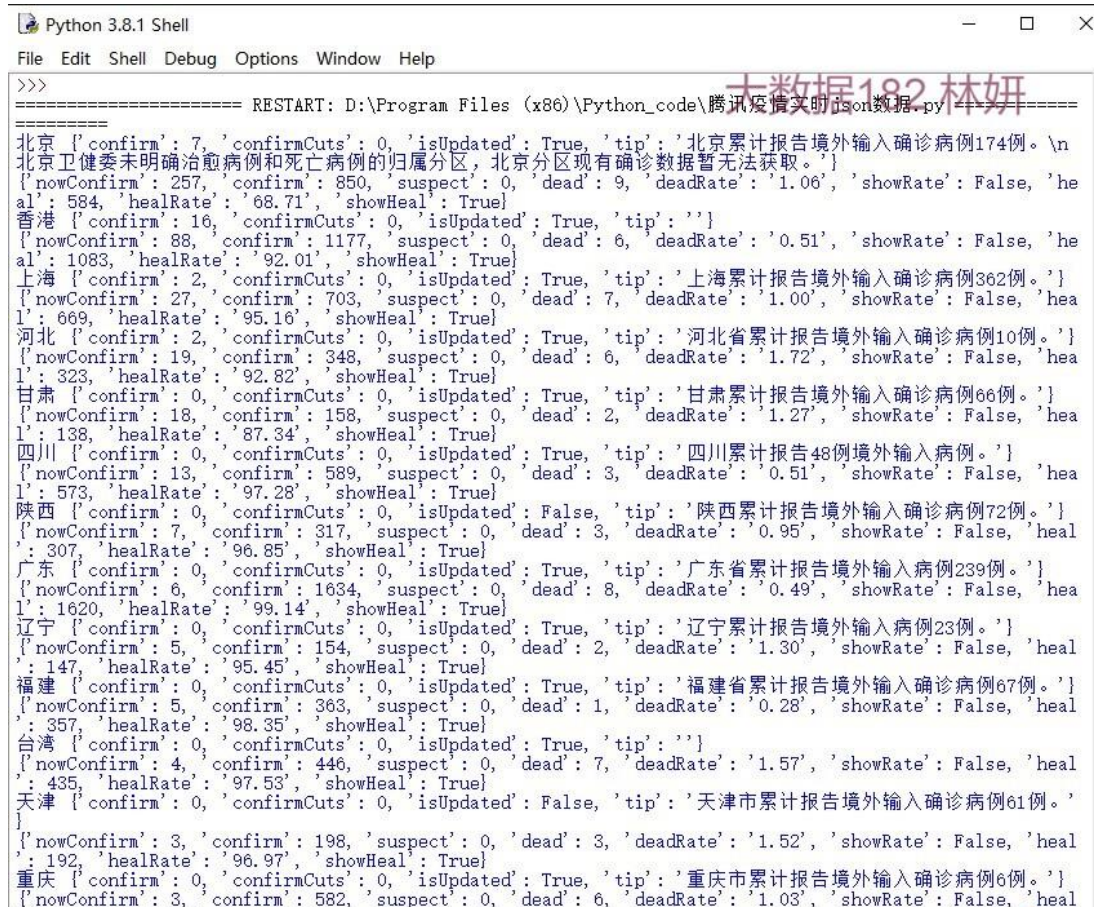
# 其他
tip = {}
for item in num:
    tip.update({item['name']:re.sub(r'\n','',item['today']['tip'])})
print("其他")
print(tip)

```

大数据182 林妍

图 4 爬取数据并初步处理数据（2）

（2）初步处理后的网页数据



```

Python 3.8.1 Shell
File Edit Shell Debug Options Window Help

>>>
===== RESTART: D:\Program Files (x86)\Python_code\腾讯疫情实时json数据.py =====
=====
北京 {'confirm': 7, 'confirmCuts': 0, 'isUpdated': True, 'tip': '北京累计报告境外输入确诊病例174例。\\n
北京卫健委未明确治愈病例和死亡病例的归属分区，北京分区现有确诊数据暂无法获取。'}
{'nowConfirm': 257, 'confirm': 850, 'suspect': 0, 'dead': 9, 'deadRate': '1.06', 'showRate': False, 'heal': 584, 'healRate': '68.71', 'showHeal': True}
香港 {'confirm': 16, 'confirmCuts': 0, 'isUpdated': True, 'tip': ''}
{'nowConfirm': 88, 'confirm': 1177, 'suspect': 0, 'dead': 6, 'deadRate': '0.51', 'showRate': False, 'heal': 1083, 'healRate': '92.01', 'showHeal': True}
上海 {'confirm': 2, 'confirmCuts': 0, 'isUpdated': True, 'tip': '上海累计报告境外输入确诊病例362例。'}
{'nowConfirm': 27, 'confirm': 703, 'suspect': 0, 'dead': 7, 'deadRate': '1.00', 'showRate': False, 'heal': 669, 'healRate': '95.16', 'showHeal': True}
河北 {'confirm': 2, 'confirmCuts': 0, 'isUpdated': True, 'tip': '河北省累计报告境外输入确诊病例10例。'}
{'nowConfirm': 19, 'confirm': 348, 'suspect': 0, 'dead': 6, 'deadRate': '1.72', 'showRate': False, 'heal': 323, 'healRate': '92.82', 'showHeal': True}
甘肃 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': '甘肃累计报告境外输入确诊病例66例。'}
{'nowConfirm': 18, 'confirm': 158, 'suspect': 0, 'dead': 2, 'deadRate': '1.27', 'showRate': False, 'heal': 138, 'healRate': '87.34', 'showHeal': True}
四川 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': '四川省累计报告48例境外输入病例。'}
{'nowConfirm': 13, 'confirm': 589, 'suspect': 0, 'dead': 3, 'deadRate': '0.51', 'showRate': False, 'heal': 573, 'healRate': '97.28', 'showHeal': True}
陕西 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': False, 'tip': '陕西累计报告境外输入确诊病例72例。'}
{'nowConfirm': 7, 'confirm': 317, 'suspect': 0, 'dead': 3, 'deadRate': '0.95', 'showRate': False, 'heal': 307, 'healRate': '96.85', 'showHeal': True}
广东 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': '广东省累计报告境外输入病例239例。'}
{'nowConfirm': 6, 'confirm': 1634, 'suspect': 0, 'dead': 8, 'deadRate': '0.49', 'showRate': False, 'heal': 1620, 'healRate': '99.14', 'showHeal': True}
辽宁 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': '辽宁省累计报告境外输入病例23例。'}
{'nowConfirm': 5, 'confirm': 154, 'suspect': 0, 'dead': 2, 'deadRate': '1.30', 'showRate': False, 'heal': 147, 'healRate': '95.45', 'showHeal': True}
福建 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': '福建省累计报告境外输入确诊病例67例。'}
{'nowConfirm': 5, 'confirm': 363, 'suspect': 0, 'dead': 1, 'deadRate': '0.28', 'showRate': False, 'heal': 357, 'healRate': '98.35', 'showHeal': True}
台湾 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': ''}
{'nowConfirm': 4, 'confirm': 446, 'suspect': 0, 'dead': 7, 'deadRate': '1.57', 'showRate': False, 'heal': 435, 'healRate': '97.53', 'showHeal': True}
天津 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': False, 'tip': '天津市累计报告境外输入确诊病例61例。'}
{'nowConfirm': 3, 'confirm': 198, 'suspect': 0, 'dead': 3, 'deadRate': '1.52', 'showRate': False, 'heal': 192, 'healRate': '96.97', 'showHeal': True}
重庆 {'confirm': 0, 'confirmCuts': 0, 'isUpdated': True, 'tip': '重庆市累计报告境外输入确诊病例6例。'}
{'nowConfirm': 3, 'confirm': 582, 'suspect': 0, 'dead': 6, 'deadRate': '1.03', 'showRate': False, 'heal': 573, 'healRate': '98.45', 'showHeal': True}

```

大数据182 林妍

图 5 网页原始数据


```

现有确诊数据
{'北京': 257, '香港': 88, '上海': 27, '河北': 19, '甘肃': 18, '四川': 13, '陕西': 7, '广东': 6, '辽宁': 5, '福建': 5, '台湾': 4, '天津': 3, '重庆': 3, '海南': 2, '江苏': 1, '内蒙古': 1, '浙江': 1, '西藏': 0, '吉林': 0, '河南': 0, '新疆': 0, '安徽': 0, '云南': 0, '黑龙江': 0, '湖北': 0, '湖南': 0, '广西': 0, '贵州': 0, '青海': 0, '澳门': 0, '宁夏': 0, '江西': 0, '山东': 0, '山西': 0}

累计确诊数据
{'北京': 850, '香港': 1177, '上海': 703, '河北': 348, '甘肃': 158, '四川': 589, '陕西': 317, '广东': 1634, '辽宁': 154, '福建': 363, '台湾': 446, '天津': 198, '重庆': 582, '海南': 171, '江苏': 654, '内蒙古': 238, '浙江': 1269, '西藏': 1, '吉林': 155, '河南': 1276, '新疆': 76, '安徽': 991, '云南': 185, '黑龙江': 947, '湖北': 68135, '湖南': 1019, '广西': 254, '贵州': 147, '青海': 18, '澳门': 45, '宁夏': 75, '江西': 932, '山东': 792, '山西': 198}

现有疑似数据
{'北京': 0, '香港': 0, '上海': 0, '河北': 0, '甘肃': 0, '四川': 0, '陕西': 0, '广东': 0, '辽宁': 0, '福建': 0, '台湾': 0, '天津': 0, '重庆': 0, '海南': 0, '江苏': 0, '内蒙古': 0, '浙江': 0, '西藏': 0, '吉林': 0, '河南': 0, '新疆': 0, '安徽': 0, '云南': 0, '黑龙江': 0, '湖北': 0, '湖南': 0, '广西': 0, '贵州': 0, '青海': 0, '澳门': 0, '宁夏': 0, '江西': 0, '山东': 0, '山西': 0}

累计死亡数据
{'北京': 9, '香港': 6, '上海': 7, '河北': 6, '甘肃': 2, '四川': 3, '陕西': 3, '广东': 8, '辽宁': 2, '福建': 1, '台湾': 7, '天津': 3, '重庆': 6, '海南': 6, '江苏': 0, '内蒙古': 1, '浙江': 1, '西藏': 0, '吉林': 2, '河南': 22, '新疆': 3, '安徽': 6, '云南': 2, '黑龙江': 13, '湖北': 4512, '湖南': 4, '广西': 2, '贵州': 2, '青海': 0, '澳门': 0, '宁夏': 0, '江西': 1, '山东': 7, '山西': 0}

死亡率
{'北京': '1.06', '香港': '0.51', '上海': '1.00', '河北': '1.72', '甘肃': '1.27', '四川': '0.51', '陕西': '0.95', '广东': '0.49', '辽宁': '1.30', '福建': '0.28', '台湾': '1.57', '天津': '1.52', '重庆': '1.03', '海南': '3.51', '江苏': '0.00', '内蒙古': '0.42', '浙江': '0.08', '西藏': '0.00', '吉林': '1.29', '河南': '1.72', '新疆': '3.95', '安徽': '0.61', '云南': '1.08', '黑龙江': '1.37', '湖北': '6.62', '湖南': '0.39', '广西': '0.79', '贵州': '1.36', '青海': '0.00', '澳门': '0.00', '宁夏': '0.00', '江西': '0.11', '山东': '0.88', '山西': '0.00'}

累计治愈数据
{'北京': 584, '香港': 1083, '上海': 669, '河北': 323, '甘肃': 138, '四川': 573, '陕西': 307, '广东': 1620, '辽宁': 147, '福建': 357, '台湾': 435, '天津': 192, '重庆': 573, '海南': 163, '江苏': 653, '内蒙古': 236, '浙江': 1267, '西藏': 1, '吉林': 153, '河南': 1254, '新疆': 73, '安徽': 985, '云南': 183, '黑龙江': 934, '湖北': 63623, '湖南': 1015, '广西': 252, '贵州': 145, '青海': 18, '澳门': 45, '宁夏': 75, '江西': 931, '山东': 785, '山西': 198}

治愈率
{'北京': '68.71', '香港': '92.01', '上海': '95.16', '河北': '92.82', '甘肃': '87.34', '四川': '97.28', '陕西': '96.85', '广东': '99.14', '辽宁': '95.45', '福建': '98.35', '台湾': '97.53', '天津': '96.97', '重庆': '98.45', '海南': '95.32', '江苏': '99.85', '内蒙古': '99.16', '浙江': '99.84', '西藏': '100.00', '吉林': '98.71', '河南': '98.28', '新疆': '96.05', '安徽': '99.39', '云南': '98.92', '黑龙江': '98.63', '湖北': '93.38', '湖南': '99.61', '广西': '99.21', '贵州': '98.64', '青海': '100.00', '澳门': '100.00', '宁夏': '100.00', '江西': '99.89', '山东': '99.12', '山西': '100.00'}

```

图 6 初步处理后的数据格式

(3) 将数据存储进 csv 文件

```

#存储数据至 CSV 文件
names = list(nowConfirm.keys())
num1 = list(nowConfirm.values())
num2 = list(total_confirm.values())
num3 = list(nowSuspect.values())
num4 = list(total_dead.values())
num5 = list(deadRate.values())
num6 = list(total_heal.values())
num7 = list(healRate.values())
num8 = list(new_confirm.values())
num9 = list(tip.values())

print(names)
print(num1)
print(num2)
print(num3)
print(num4)
print(num5)
print(num6)
print(num7)
print(num8)
print(num9)

# 文件名"202180403_林妍_2020-6-24_疫情数据.csv"
n = "202180403_林妍_" + time.strftime("%Y-%m-%d") + "疫情数据.csv"
fw = open(n, 'w', encoding='utf-8')
fw.write('province,nowConfirm,confirm,nowSuspect,dead,deadRate,heal,healRate,'
for i in range(len(names)):
    print(str(names[i]) + ',' + str(num1[i]) + ',' + str(num2[i]) + ',' + str(num3[i]) + ','
    fw.write(str(names[i]) + ',' + str(num1[i]) + ',' + str(num2[i]) + ',' + str(num3[i])
else:
    print("Over write file!")
    fw.close()

```

图 7 将数据存入 csv 文件源码

北京, 257, 850, 0, 9, 1.06, 584, 68.71, 7, 北京累计报告境外输入确诊病例174例。北京卫健委未明确治愈病例和死亡病例的归属分区, 北京分区现有确诊数据暂无法获取。
香港, 88, 1177, 0, 6, 0.51, 1083, 92.01, 16,
上海, 27, 703, 0, 7, 1.00, 669, 95.16, 2, 上海累计报告境外输入确诊病例362例。
河北, 19, 348, 0, 6, 1.72, 323, 92.82, 2, 河北省累计报告境外输入确诊病例10例。
甘肃, 18, 158, 0, 2, 1.27, 138, 87.34, 0, 甘肃累计报告境外输入确诊病例66例。
四川, 13, 589, 0, 3, 0.51, 573, 97.28, 0, 四川累计报告48例境外输入病例。
陕西, 7, 317, 0, 3, 0.95, 307, 96.85, 0, 陕西累计报告境外输入确诊病例72例。
广东, 6, 1634, 0, 8, 0.49, 1620, 99.14, 0, 广东省累计报告境外输入病例239例。
辽宁, 5, 154, 0, 2, 1.30, 147, 95.45, 0, 辽宁累计报告境外输入病例23例。
福建, 5, 363, 0, 1, 0.28, 357, 98.35, 0, 福建省累计报告境外输入确诊病例67例。
台湾, 4, 446, 0, 7, 1.57, 435, 97.53, 0,
天津, 3, 198, 0, 3, 1.52, 192, 96.97, 0, 天津市累计报告境外输入确诊病例61例。
重庆, 3, 582, 0, 6, 1.03, 573, 98.45, 0, 重庆市累计报告境外输入确诊病例6例。
海南, 2, 171, 0, 6, 3.51, 163, 95.32, 0, 海南省累计报告境外输入确诊病例2例。
江苏, 1, 654, 0, 0, 0.00, 653, 99.85, 0, 江苏累计报告境外输入确诊病例23例。
内蒙古, 1, 238, 0, 1, 0.42, 236, 99.16, 0, 内蒙古自治区累计报告境外输入确诊病例161例。
浙江, 1, 1269, 0, 1, 0.08, 1267, 99.84, 0, 浙江累计报告境外输入确诊病例50例。
西藏, 0, 1, 0, 0, 0.00, 1, 100.00, 0,
吉林, 0, 155, 0, 2, 1.29, 153, 98.71, 0, 吉林累计报告境外输入确诊病例19例。
河南, 0, 1276, 0, 22, 1.72, 1254, 98.28, 0, 河南累计报告3例境外输入型病例。
新疆, 0, 76, 0, 3, 3.95, 73, 96.05, 0,

大数据182 林妍

图 8 存入 csv 文件的数据格式

(4) csv 文件中的数据

202180403_...-06-24疫情数据													
开始 插入 页面布局 公式 数据 审阅 视图 安全 开发工具 特色功能 查找													
B I U 田 格式刷 合并居中 自动换行 条件格式 表格样式 文档													
A1 province													
A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	province	nowConfir	confirm	nowSuspec	dead	deadRate	heal	healRate	new_confir	tip			
2	北京	257	850	0	9	1.06	584	68.71	7	北京累计报告境外输入确诊病例174例。北京卫健委			
3	香港	88	1177	0	6	0.51	1083	92.01	16				
4	上海	27	703	0	7	1	669	95.16	2	上海累计报告境外输入确诊病例362例。			
5	河北	19	348	0	6	1.72	323	92.82	2	河北省累计报告境外输入确诊病例10例。			
6	甘肃	18	158	0	2	1.27	138	87.34	0	甘肃累计报告境外输入确诊病例66例。			
7	四川	13	589	0	3	0.51	573	97.28	0	四川累计报告48例境外输入病例。			
8	陕西	7	317	0	3	0.95	307	96.85	0	陕西累计报告境外输入确诊病例72例。			
9	广东	6	1634	0	8	0.49	1620	99.14	0	广东省累计报告境外输入病例239例。			
10	辽宁	5	154	0	2	1.3	147	95.45	0	辽宁累计报告境外输入病例23例。			
11	福建	5	363	0	1	0.28	357	98.35	0	福建省累计报告境外输入确诊病例67例。			
12	台湾	4	446	0	7	1.57	435	97.53	0				
13	天津	3	198	0	3	1.52	192	96.97	0	天津市累计报告境外输入确诊病例61例。			
14	重庆	3	582	0	6	1.03	573	98.45	0	重庆市累计报告境外输入确诊病例6例。			
15	海南	2	171	0	6	3.51	163	95.32	0	海南省累计报告境外输入确诊病例2例。			
16	江苏	1	654	0	0	0	653	99.85	0	江苏累计报告境外输入确诊病例23例。			
17	内蒙古	1	238	0	1	0.42	236	99.16	0	内蒙古自治区累计报告境外输入确诊病例161例。			
18	浙江	1	1269	0	1	0.08	1267	99.84	0	浙江累计报告境外输入确诊病例50例。			
19	西藏	0	1	0	0	0	1	100	0				
20	吉林	0	155	0	2	1.29	153	98.71	0	吉林累计报告境外输入确诊病例19例。			
21	河南	0	1276	0	22	1.72	1254	98.28	0	河南累计报告3例境外输入型病例。			
22	新疆	0	76	0	3	3.95	73	96.05	0				
23	安徽	0	991	0	6	0.61	985	99.39	0	安徽省累计报告境外输入确诊病例1例。			
24	云南	0	185	0	2	1.08	183	98.92	0	云南省累计报告境外输入确诊病例11例。			
25	黑龙江	0	947	0	13	1.37	934	98.63	0	黑龙江省累计报告境外输入确诊病例386例。			
26	湖北	0	68135	0	4512	6.62	63623	93.38	0				
27	湖南	0	1019	0	4	0.39	1015	99.61	0	湖南省累计报告境外输入确诊病例1例。			

图 9 csv 文件中的数据

二、使用 DataX 技术导入舆情热点数据 CSV 文件到数据库

1. 在 mysql 数据库中新建表格




图 10 mysql 建表语句

2. 将 csv 文件上传至虚拟机




图 11 将爬取的网页数据传至虚拟机

3. 将 csv 文件移动到对应的文件夹

```
hadoop@linyan-virtual-machine:/opt/datax$ sudo mv /home/hadoop/coronavirus.csv  
/opt/datax/job  
[sudo] hadoop 的密码:
```

大数据182 林妍

图 12 移动文件到工作目录下

4. 查看配置模板

```
hadoop@linyan-virtual-machine:~$ cd /opt/datax  
hadoop@linyan-virtual-machine:/opt/datax$ python /opt/datax/bin/datax.py -r txt  
filereader -w mysqlwriter  
  
DataX (DATAX-OPENSOURCE-3.0), From Alibaba !  
Copyright (C) 2010-2017, Alibaba Group. All Rights Reserved.  
  
Please refer to the txtfilereader document:  
https://github.com/alibaba/DataX/blob/master/txtfilereader/doc/txtfilereader.md  
  
Please refer to the mysqlwriter document:  
https://github.com/alibaba/DataX/blob/master/mysqlwriter/doc/mysqlwriter.md  
  
Please save the following configuration as a json file and use  
python {DATAX_HOME}/bin/datax.py {JSON_FILE_NAME}.json  
to run the job.  
  
{  
  "job": {  
    "content": [  
      {  
        "reader": {  
          "name": "txtfilereader",  
          "parameter": {  
            "column": [],  
            "encoding": "",  
            "fieldDelimiter": "",  
            "path": []  
          }  
        },  
        "writer": {  
          "name": "mysqlwriter",  
          "parameter": {  
            "column": [],  
            "connection": [  
              {  
                "jdbcUrl": "",  
                "table": []  
              }  
            ],  
            "password": "",  
            "preSql": [],  
            "session": [],  
            "username": "",  
            "writeMode": ""  
          }  
        }  
      ],  
      "setting": {  
        "speed": {  
          "channel": ""  
        }  
      }  
    }  
  }  
}
```

大数据182 林妍

图 13 DataX 查看配置模板

5. json 配置文件

```
{
  "content": [
    {
      "reader": {
        "name": "txtfilereader",
        "parameter": {
          "column": [
            {
              "index": 0,
              "type": "string"
            },
            {
              "index": 1,
              "type": "string"
            },
            {
              "index": 2,
              "type": "string"
            },
            {
              "index": 3,
              "type": "string"
            },
            {
              "index": 8,
              "type": "string"
            },
            {
              "index": 9,
              "type": "string"
            }
          ],
          "encoding": "UTF-8",
          "fieldDelimiter": ",",
          "path": [
            "/opt/datax/job/coronavirus.csv"
          ]
        }
      },
      "writer": {
        "name": "mysqlwriter",
        "parameter": {
          "column": [
            "province",
            "nowConfirm",
            "confirm",
            "nowSuspect",
            "dead",
            "deadRate",
            "heal",
            "healRate",
            "new_confirm",
            "tip"
          ],
          "connection": [
            {
              "jdbcUrl": "jdbc:mysql://39.98.224.249:3306/cai_jl_ly?useUnicode=true&characterEncoding=utf8",
              "table": [
                "coronavirus"
              ]
            }
          ],
          "password": "*****",
          "preSql": [
            "delete from coronavirus"
          ]
        }
      }
    }
  ]
}
```

图 14 json 配置文件（1）

```
    "encoding": "UTF-8",
    "fieldDelimiter": ",",
    "path": [
      "/opt/datax/job/coronavirus.csv"
    ]
  },
  "writer": {
    "name": "mysqlwriter",
    "parameter": {
      "column": [
        "province",
        "nowConfirm",
        "confirm",
        "nowSuspect",
        "dead",
        "deadRate",
        "heal",
        "healRate",
        "new_confirm",
        "tip"
      ],
      "connection": [
        {
          "jdbcUrl": "jdbc:mysql://39.98.224.249:3306/cai_jl_ly?useUnicode=true&characterEncoding=utf8",
          "table": [
            "coronavirus"
          ]
        }
      ],
      "password": "*****",
      "preSql": [
        "delete from coronavirus"
      ]
    }
  }
}
```

图 15 json 配置文件（2）

三、使用 Kettle 技术对舆情热点数据进行清洗、过滤等操作

1. 新建表格用于存放处理后的数据



图 19 新建表用于存放处理后的数据

2. 数据库连接编码设置




图 20 Kettle 连接数据库的编码设置 (1)



图 21 Kettle 连接数据库的编码设置 (2)

3. job 任务结构



图 22 kettle 的 job 任务结构

4. 表输入控件



图 23 表输入控件编辑详情

5. 字段选择控件



图 24 字段选择控件编辑详情

6. 表输出控件



图 25 表输出控件编辑详情

7. job 执行结果



图 26 kettle 的 job 运行转换结果

8. 查看数据库中存储的数据

对象

* 无标题 - 查询

virtus @cai_ji_ly (library) - ...

coronavirus @cai_ji_ly (libr...

开始事务

文本

筛选

排序

导入

导出

大数据102 林妍

province	nowConfirm	confirm	dead	deadRate	heal	healRate	new_confirm
北京	257	850	9	1.06	584	68.71	7
香港	88	1177	6	0.51	1083	92.01	16
上海	27	703	7	1.00	669	95.16	2
河北	19	348	6	1.72	323	92.82	2
甘肃	18	158	2	1.27	138	87.34	0
四川	13	589	3	0.51	573	97.28	0
▶ 陕西	7	317	3	0.95	307	96.85	0
广东	6	1634	8	0.49	1620	99.14	0
辽宁	5	154	2	1.30	147	95.45	0
福建	5	363	1	0.28	357	98.35	0
台湾	4	446	7	1.57	435	97.53	0
天津	3	198	3	1.52	192	96.97	0
重庆	3	582	6	1.03	573	98.45	0
海南	2	171	6	3.51	163	95.32	0
江苏	1	654	0	0.00	653	99.85	0
内蒙古	1	238	1	0.42	236	99.16	0
浙江	1	1269	1	0.08	1267	99.84	0
西藏	0	1	0	0.00	1	100.00	0
吉林	0	155	2	1.29	153	98.71	0
河南	0	1276	22	1.72	1254	98.28	0

+ - ✓ ✕ C


图 27 处理后的数据格式

四、数据展示

1. 下载必要的第三方库


pip install pymysql

pip install matplotlib



```
选择Windows PowerShell
PS D:\Program Files\Python\Scripts> pip install pymysql
Collecting pymysql
  Downloading PyMySQL-0.9.3-py2.py3-none-any.whl (47 kB)
    | 47 kB 241 kB/s
Installing collected packages: pymysql
Successfully installed pymysql-0.9.3
WARNING: You are using pip version 20.0.2; however, version 20.1.1 is available.
You should consider upgrading via the 'd:\program files\python\python.exe -m pip install --upgrade pip' command.
PS D:\Program Files\Python\Scripts>
```

图 28 下载第三方库 pymysql



```
Windows PowerShell
PS D:\Program Files\Python\Scripts> pip install matplotlib
Collecting matplotlib
  Downloading matplotlib-3.2.2-cp38-cp38-win amd64.whl (9.2 MB)
    | 9.2 MB 181 kB/s
Collecting python-dateutil>=2.1
  Downloading python-dateutil-2.8.1-py2.py3-none-any.whl (227 kB)
    | 227 kB 181 kB/s
Requirement already satisfied: numpy>=1.11 in d:\program files\python\lib\site-packages (from matplotlib) (1.18.1)
Collecting cycler>=0.10
  Downloading cycler-0.10.0-py2.py3-none-any.whl (6.5 kB)
Collecting pyparsing!=2.0.4,!=2.1.2,!=2.1.6,>=2.0.1
  Downloading pyparsing-2.4.7-py2.py3-none-any.whl (67 kB)
    | 67 kB 113 kB/s
Collecting kiwisolver>=1.0.1
  Downloading kiwisolver-1.2.0-cp38-cp38-win amd64.whl (58 kB)
    | 58 kB 117 kB/s
Collecting six>=1.5
  Downloading six-1.15.0-py2.py3-none-any.whl (10 kB)
Installing collected packages: six, python-dateutil, cycler, pyparsing, kiwisolver, matplotlib
Successfully installed cycler-0.10.0 kiwisolver-1.2.0 matplotlib-3.2.2 pyparsing-2.4.7 python-dateutil-2.8.1 six-1.15.0
WARNING: You are using pip version 20.0.2; however, version 20.1.1 is available.
You should consider upgrading via the 'd:\program files\python\python.exe -m pip install --upgrade pip' command.
PS D:\Program Files\Python\Scripts>
```

图 29 下载第三方库 matplotlib

2. 从数据库中读取处理好的数据



```
virus.py - D:\Program Files (x86)\Python_code\virus.py (3.8.1)
File Edit Format Run Options Window Help

import pymysql as MySQLdb
import datetime
import matplotlib.pyplot as plt
import numpy as np

host = '39.98.224.249'
user = 'root'
passwd = 'ntly12345.'
port = 3306
db = 'cai_ji_ly'

try:
    conn = MySQLdb.connect(host=host,port=port,user=user,passwd=passwd,db=db,charset='utf8', )
    cur = conn.cursor()
except Exception as e:
    print('Connect MySQL Database Fail: ' + e)

sql = 'select * from virtus'
cur.execute(sql)
result = cur.fetchall()
headers = ('province', 'nowConfirm', 'confirm', 'dead', 'deadRate', 'heal', 'healRate', 'new_confirm')
results = [dict(zip(headers, row)) for row in result]

cur.close()
conn.close()

province = [item['province'] for item in results]
nowConfirm = [eval(item['nowConfirm']) for item in results]
confirm = [eval(item['confirm']) for item in results]
dead = [eval(item['dead']) for item in results]
deadRate = [eval(item['deadRate']) for item in results]
heal = [eval(item['heal']) for item in results]
healRate = [eval(item['healRate']) for item in results]
new_confirm = [eval(item['new_confirm']) for item in results]

print(province)
```

图 30 python 从数据库读取数据代码

3. 制图

```
def picture(data, yTitle, color1):
    print(data)
    plt.figure(figsize=[50, 50])
    plt.rcParams['font.sans-serif'] = ['SimHei'] #用来正常显示中文标签
    plt.rcParams['axes.unicode_minus'] = False #用来正常显示负号
    # 获取数据
    plt.bar(province, data, 0.5, color=color1)
    # 设置标题
    plt.xlabel("地区")
    plt.ylabel(yTitle)
    plt.xticks(list(province), size=9)
    # 显示数字
    for a, b in zip(list(province), list(data)):
        plt.text(a, b, b, ha='center', va='bottom', size=8.3)
    plt.show()

picture(nowConfirm, "现存确诊人数/人", "#4C8DAE")
picture(confirm, "累计确诊人数/人", "#4C8DAE")
picture(new_confirm, "新增确诊人数/人", "#7397AB")
#picture(dead, "死亡人数/人", "#C83C23")
#picture(deadRate, "死亡率/%", "#C83C23")
#picture(heal, "治愈人数/人", "#21A675")
#picture(healRate, "治愈率/%", "#21A675")
```

图 31 绘制各省份数据展示图代码

4. 现存确诊人数




图 32 各省份新冠肺炎现存确诊人数图

5. 累计确诊人数




图 33 各省份新冠肺炎累计确诊人数图

6. 新增确诊人数




图 34 各省份新冠肺炎新增确诊人数图

7. 死亡人数




图 35 各省份新冠肺炎死亡人数图

8. 死亡率




图 36 各省份新冠肺炎死亡率图

9. 治愈人数




图 37 各省份新冠肺炎治愈人数图

10. 治愈率




图 38 各省份新冠肺炎治愈率图

四、实验结果分析和总结

从图表显示来看，北京、香港目前是疫情重灾区，现存确诊人数较多，上海、河北等地现存确诊人数也相对较多，由于现存的患者多，所以治愈率偏低；湖北是我国疫情首发地，虽然死亡率略高于其他省份，但是已经做得很不错了。