

南京工程学院

实 验 报 告

课 程 名 称 _____ 大数据采集技术 _____

实 验 项 目 _____ 舆情热点大数据平台数据采集设计与实现 _____

学 号 _____ 202180436 _____

姓 名 _____ 于 _____

班 级 _____ 大数据（嵌入）182 _____

实 验 时 间 _____ 2020 年 6 月 28 日 _____

实 验 地 点 _____

实验成绩评定 _____

指导教师签字 _____ 年 _____ 月

实验六 舆情热点大数据采集

一、实验目标

1. 掌握舆情热点大数据采集技术的基本理论，熟悉其基本框架；
2. 通过实验了解舆情热点大数据采集技术的各个环节和应用；
3. 熟悉舆情热点大数据采集技术软件和环境搭建，并简单完成三类数据采集案例。

二、实验平台

操作系统：Linux

JDK 版本：1.8 或以上版本

Kafka 版本：2.0 或以上版本

Kettle 版本：3.4.8 或以上版本

Datax

三、实验内容

主要包括：

2.1 Kafka 的基本理论

2.2 实验内容：

- 1、Java 安装和环境配置；
- 2、Kettler、Datax 装和环境配置；
- 3、Kafka 安装和验证；
- 4、基于舆情热点大数据简单的数据采集案例（教材中的三个之一或其它形式的）；

3.1 基本理论

- 1) 参阅教材，2) 参阅课件 PPT，3) 参阅网络资源。

1、组成和架构

组成：

网络爬虫技术、datax 抽取技术、kettle 清洗技术、数据库存储

架构图：



架构说明：


利用爬虫技术获取各种舆情热点信息，根据关键词对它们执行清洗操作，之后再把清洗过的数据保存下来，接下来收集更多的数据，清洗新的数据并把清洗结果与前面处理完的结果数据结合起来，重新进行清洗、保存等操作，以获得更加准确、完整的舆情信息。

2、工作流程


工作流程图：

爬取流程

图6-2 数据爬取流程



工作流程



步骤说明：

舆情热点数据需要采用爬虫技术从互联网获取，并保存到.CSV 文件中。

创建数据库，使用 datax 技术导入舆情热点数据，把 CSV 文件抽取至 MySQL 数据库。

使用 kettle 技术对舆情热点数据进行清洗、去重、过滤、格式化等操作。

3.2 实验内容

1. 安装和环境配置 JDK、Kettle、Datax、等

Jdk 安装

```
hadoop@yu-VirtualBox:~$ java -version
openjdk version "1.8.0_252"
OpenJDK Runtime Environment (build 1.8.0_252-8u252-b09-1~18.04-b09)
OpenJDK 64-Bit Server VM (build 25.252-b09, mixed mode)
```

Datax 安装

下载

```
hadoop@yu-VirtualBox:~/下载$ sudo tar -xvf datax.tar.gz -C /home/hadoop/
datax/
datax/conf/
datax/conf/logback.xml
datax/conf/.secret.properties
datax/conf/core.json
datax/job/
datax/job/job.json
datax/script/
datax/script/Readme.md
datax/lib/
datax/lib/commons-lang-2.6.jar
datax/lib/commons-cli-1.2.jar
datax/lib/commons-io-2.4.jar
datax/lib/logback-classic-1.0.13.jar
datax/lib/commons-codec-1.9.jar
datax/lib/httpcore-4.4.jar
```

验证安装

```
hadoop@yu-VirtualBox:~/datax/bin$ cd /home/hadoop/datax/bin
hadoop@yu-VirtualBox:~/datax/bin$ python datax.py ../job/job.json

DataX (DATAX-OPENSOURCE-3.0), From Alibaba !
Copyright (C) 2010-2017, Alibaba Group. All Rights Reserved.

2020-05-22 14:13:29.905 [job-0] INFO JobContainer - PerfTrace not enable!
2020-05-22 14:13:29.906 [job-0] INFO StandAloneJobContainerCommunicator - Total
100000 records, 2600000 bytes | Speed 253.91KB/s, 10000 records/s | Error 0 rec
ords, 0 bytes | All Task WaitWriterTime 0.023s | All Task WaitReaderTime 0.217
s | Percentage 100.00%
2020-05-22 14:13:29.910 [job-0] INFO JobContainer -
任务启动时刻          : 2020-05-22 14:13:19
任务结束时刻          : 2020-05-22 14:13:29
任务总计耗时          : 10s
任务平均流量          : 253.91KB/s
记录写入速度          : 10000rec/s
读出记录总数          : 100000
读写失败总数          : 0
```

Kettle 安装

下载解压

```
hadoop@yu-VirtualBox:~$ cd /soft
hadoop@yu-VirtualBox:/soft$ unzip pdi-ce-7.1.0.0-12.zip
Archive:  pdi-ce-7.1.0.0-12.zip
  creating: data-integration/
  creating: data-integration/adaptive-execution/
  creating: data-integration/adaptive-execution/bin/
  creating: data-integration/adaptive-execution/bin/contrib/
  creating: data-integration/adaptive-execution/system/
  creating: data-integration/adaptive-execution/system/org/
  creating: data-integration/adaptive-execution/system/org/apache/
  creating: data-integration/adaptive-execution/system/org/apache/aries/
  creating: data-integration/adaptive-execution/system/org/apache/aries/rsa/
  creating: data-integration/adaptive-execution/system/org/apache/aries/rsa/discovery/
  creating: data-integration/adaptive-execution/system/org/apache/aries/rsa/discovery/org/apache/aries/rsa/discovery/command/
```

启动界面

```
hadoop@yu-VirtualBox:~$ cd /soft/kettle
hadoop@yu-VirtualBox:/soft/kettle$ ./spoon.sh
OpenJDK 64-Bit Server VM warning: ignoring option MaxPermSize=256m; support was
removed in 8.0
Gtk-Messgae: 14:07:19.515: Failed to load module "canberra-gtk-module"
14:07:23,289 INFO  [KarafBoot] Checking to see if org.pentaho.clean.karaf.cache
is enabled
14:07:23,533 INFO  [KarafInstance]
*****
*** Karaf Instance Number: 1 at /soft/kettle/./system/karaf/caches/spoon/da ***
*** ta-1 ***
*** FastBin Provider Port:52901 ***
*** Karaf Port:8802 ***
*** OSGI Service Port:9051 ***
*****
五月 29, 2020 2:07:24 下午 org.apache.karaf.main.Main launch
信息: Installing and starting initial bundles
五月 29, 2020 2:07:24 下午 org.apache.karaf.main.Main launch
信息: All initial bundles installed and set to start
五月 29, 2020 2:07:25 下午 org.apache.karaf.main.Main$KarafLockCallback lockAcq
ired
信息: Lock acquired. Setting startlevel to 100
Creating configuration from org.apache.karaf.command.acl.kar.cfg
Creating configuration from jmx.acl.cfg
Creating configuration from org.apache.activemq.webconsole.cfg
```

2. 实例测试

为 python 运行安装 requests 库

```
Microsoft Windows [版本 10.0.18362.900]
(c) 2019 Microsoft Corporation. 保留所有权利。

C:\Users\岱>pip install requests
Collecting requests
  Downloading https://files.pythonhosted.org/packages/45/1e/0c169c6a5381e241ba7404532c16a21d86
ab872c9bed8bdcd4c423954103/requests-2.24.0-py2.py3-none-any.whl (61kB)
100% |#####| 71kB 308kB/s
Collecting certifi>=2017.4.17 (from requests)
  Downloading https://files.pythonhosted.org/packages/5e/c4/6c4fe722df5343c33226f0b4e0bb042e4c
c13483228b4718baf286f86d87/certifi-2020.6.20-py2.py3-none-any.whl (156kB)
100% |#####| 163kB 593kB/s
Collecting urllib3!=1.25.0,!=1.25.1,<1.26,>=1.21.1 (from requests)
  Downloading https://files.pythonhosted.org/packages/e1/e5/df302e8017440f11c1cc41a6b4328386
72f5a70aa29227bf58149dc72f/urllib3-1.25.9-py2.py3-none-any.whl (126kB)
100% |#####| 133kB 290kB/s
Collecting idna<3,>=2.5 (from requests)
  Downloading https://files.pythonhosted.org/packages/89/e3/afebe61c546d18fb1709a61bee788254b4
0e736cff7271c7de5de2dc4128/idna-2.9-py2.py3-none-any.whl (58kB)
100% |#####| 61kB 272kB/s
Collecting chardet<4,>=3.0.2 (from requests)
  Downloading https://files.pythonhosted.org/packages/bc/a9/01ffebfb562e4274b6487b4bb1ddec7ca5
5ec7510b22e4c51f14098443b8/chardet-3.0.4-py2.py3-none-any.whl (133kB)
100% |#####| 143kB 335kB/s
Installing collected packages: certifi, urllib3, idna, chardet, requests
  The script chardet.exe is installed in 'c:\users\岱\appdata\local\programs\python\python3
7\Scripts' which is not on PATH.
  Consider adding this directory to PATH or, if you prefer to suppress this warning, use --no
warn-script-location.
```

获取头条热点新闻标题元素和内容元素

今日头条

推荐

西瓜视频

热点

疫情速报

印度新增确诊18552例 累计超过50万例

人民日报海外网 · 1866评论 · 22分钟前

赢得支持？韩国独立委员会给出结论，不赞成检方起诉

DevTools - www.toutiao.com/ch/news_hot/

Network tab showing a request to `?category=news_hot&utm_source=toutiao`. The response is a JSON array of news items.

```
{
  "has_more": false,
  "message": "success",
  "data": [
    {
      "single_mode": false,
      "abstract": "据韩国媒体报道，6月26日，一个独立的调查审议委员会给出结论称，韩",
      "chinese_tag": "国际",
      "single_mode": true
    },
    {
      "single_mode": false,
      "abstract": "6月27日消息，6月26日，京东发布公告宣布，将收购京东数科36.8%的股",
      "single_mode": true
    },
    {
      "single_mode": false,
      "abstract": "26日，仅一天时间，各大互联网平台共清理涉毒品音视频、文章1927条",
      "single_mode": true
    }
  ]
}
```

查看请求的 url

Headers tab showing the Request URL:

```
Request URL: https://www.toutiao.com/api/pc/feed/?category=news_hot&utm_source=toutiao&widen=1&max_behot_time=0&max_behot_time_tmp=0&tadrequire=true&as=A135FE3F27A16D7&cp=5EF7C166BD37CE1&_signature=_02B4Z6wo0f01JLPDwwAAIBB34HfN-xAbAySywnAAHpMG60MbY-XtLfMmCAvr3mwVdAGuUStofoos-Njeds1R6nHBAM5WHV4n6bPYHdW9yuO1AMxDHJ5KuBgIx6nxa-OfdFLMS92-NLEPEBg58
```

使用 python 爬取数据

```
import requests
import json
from openpyxl import Workbook
import time
import hashlib
import os
import datetime

start_url = 'https://www.toutiao.com/api/pc/feed/?category=news_hot&utm_source=toutiao'
url = 'https://www.toutiao.com'

headers = {
    'user-agent': 'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_12_3) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/62.0.3202.94 Safari/537.36'
}

cookies = {'tt_webid': '6649949084894053895'} # 此处cookies可从浏览器中查找，为了

max_behot_time = '0' # 链接参数
title = [] # 存储新闻标题
source_url = [] # 存储新闻的链接
s_url = [] # 存储新闻的完整链接
source = [] # 存储发布新闻的公众号
media_url = {} # 存储公众号的完整链接

def get_as_cp(): # 该函数主要是为了获取as和cp参数，程序参考今日头条中的加密js文
    zz = {}
    now = round(time.time())
    print(now) # 获取当前计算机时间
    e = hex(int(now)).upper()[2:] # hex() 转换一个整数对象为16进制的字符串表示
    print('e:', e)
    a = hashlib.md5(e).hexdigest() # hashlib.md5().hexdigest() 创建hash对象并返回16进制结果
    print('a:', a)
    a.update(str(int(now)).encode('utf-8'))
    i = a.hexdigest().upper()
    print('i:', i)
    if len(e) != 8:
        zz = {'as': '470BB4B7254C150'}
```


查看爬取结果

```
6857729550', 'media_url': '/c/user/token/MS4wLjABAAAoWJPBrqzTmUsNPqSZDmC6epQp0Z
ly_vex7HGAMquco4/']], 'next': {'max_behot_time': 1593250601}}
1593251971
标题: 心中最重要的位置
新闻链接: https://www.toutiao.com/group/6842940743472906766/
头条号: 新华社
11
标题: 真正做到为官一任,造福一方
新闻链接: https://www.toutiao.com/group/6842897032844149256/
头条号: 求是网
11
标题: 超62.7万!俄罗斯单日新增新冠肺炎确诊病例6852例,累计627646例
新闻链接: https://www.toutiao.com/group/6842931487927435789/
头条号: 环球网
11
标题: 阿尔特塔:我将尽力向球员解释,踢足总杯决赛是多么美妙的事
新闻链接: https://www.toutiao.com/group/6842784786017157646/
头条号: 懂球帝
11
标题: 印度累计新冠病例数超过50万例
新闻链接: https://www.toutiao.com/group/6842922042551960077/
头条号: 环球网
11
标题: 电讯报:曼城已经签下凯尔特人16岁青训天才
新闻链接: https://www.toutiao.com/group/6842606729423749645/
头条号: 懂球帝
11
标题: 特维斯:将捐出未来半年收入,不想再看到钱!申花把他养肥了?
新闻链接: https://www.toutiao.com/group/6842864657556832771/
头条号: 菱镜头
```

将结果存储到 CSV 文件

标题	新闻链接	头条号	头条号链接						
心中最重	https://v	新华社	https://www.toutiao.com/c/user/token/MS4wLjABAAAiAce5qhH31TeuB3UdpFMV8u-						
真正做到	https://v	求是网	https://www.toutiao.com/c/user/token/MS4wLjABAAA0lmJ9IxGZz_nQOQCp7Gzr8YH						
超62.7万	https://v	环球网	https://www.toutiao.com/c/user/token/MS4wLjABAAAavazHMceCo3MeM9IJb11231AC						
阿尔特塔	https://v	懂球帝	https://www.toutiao.com/c/user/token/MS4wLjABAAAANYOU-99995oQ-z00nErj1KP2						
印度累计	https://v	环球网	https://www.toutiao.com/c/user/token/MS4wLjABAAAavazHMceCo3MeM9IJb11231AC						
电讯报:	https://v	懂球帝	https://www.toutiao.com/c/user/token/MS4wLjABAAAANYOU-99995oQ-z00nErj1KP2						
特维斯:	https://v	菱镜头	https://www.toutiao.com/c/user/token/MS4wLjABAAAAPaXmdC2DXe-415-h2nrseKY						
等深线	https://v	等深线	https://www.toutiao.com/c/user/token/MS4wLjABAAAAbPce1E3LGQoOrfHCRazM2m-vl						
俄共议员	https://v	参考消息	https://www.toutiao.com/c/user/token/MS4wLjABAAAACzSJ6Sr__f9V0khdmvXdM8W1						
墨西哥北	https://v	界面快讯	https://www.toutiao.com/c/user/token/MS4wLjABAAAACoNe1U1lvkzaakSZ03Wr3MnG						
克洛普婉	https://v	扬眼	https://www.toutiao.com/c/user/token/MS4wLjABAAAoWJPBrqzTmUsNPqSZDmC6epQ						
外媒:疫	https://v	参考消息	https://www.toutiao.com/c/user/token/MS4wLjABAAAACzSJ6Sr__f9V0khdmvXdM8W1						
PS5全新黑	https://v	游侠网	https://www.toutiao.com/c/user/token/MS4wLjABAAAAb4QccTktYXK7so0qQ9aJ4ef						
迪马:阿	https://v	直播吧	https://www.toutiao.com/c/user/token/MS4wLjABAAAiiGR2WNv1Gefhkn8pdahsZs						

在 MySQL 数据库创建 news 表存储数据

```
mysql> create table news(title varchar(50),newslink varchar(100),toutiao varchar(10),ttlink varchar(100));
Query OK, 0 rows affected (0.02 sec)

mysql>
```

查看表结构

```
mysql> describe news;
+-----+-----+-----+-----+-----+-----+
| Field | Type          | Null | Key | Default | Extra |
+-----+-----+-----+-----+-----+-----+
| title | varchar(50)   | YES  |     | NULL    |       |
| newslink | varchar(100) | YES  |     | NULL    |       |
| toutiao | varchar(10)  | YES  |     | NULL    |       |
| ttlink | varchar(100) | YES  |     | NULL    |       |
+-----+-----+-----+-----+-----+-----+
4 rows in set (0.00 sec)
```

利用 datax 技术, 将 CSV 文件导入 MySQL 数据库 news 表
编写 json 文件

```
hadoop@yu-VirtualBox:~$ cd '/home/hadoop/datax/job'  
hadoop@yu-VirtualBox:~/datax/job$ vim news.json
```

Reader 插件

```
{  
  "reader": {  
    "name": "txtfilereader",  
    "parameter": {  
      "path": ["/home/hadoop/下载/news.csv"],  
      "encode": "utf8",  
      "column": [  
        {  
          "index": 0,  
          "type": "string"  
        }, {  
          "index": 1,  
          "type": "string"  
        }, {  
          "index": 2,  
          "type": "string"  
        }, {  
          "index": 3,  
          "type": "string"  
        }  
      ],  
      "fieldDelimiter": ",",  
    }  
  },  
}
```

Writer 插件

```
{  
  "writer": {  
    "name": "mysqlwriter",  
    "parameter": {  
      "writeMode": "insert",  
      "username": "yu",  
      "password": "Ymd19991208.",  
      "column": [  
        "title",  
        "newslink",  
        "toutiao",  
        "ttlink"  
      ],  
      "preSql": [  
        "truncate table news"  
      ],  
      "connection": [  
        {  
          "jdbcUrl": "jdbc:mysql://localhost:3306/test?  
useUnicode=true&characterEncoding=utf-8",  
          "table": [  
            "news"  
          ]  
        }  
      ]  
    }  
  },  
}
```


运行json 文件

```
hadoop@yu-VirtualBox:~/datax/bin$ python datax.py ../job/news.json

DataX (DATAX-OPENSOURCE-3.0), From Alibaba !
Copyright (C) 2010-2017, Alibaba Group. All Rights Reserved.

2020-06-28 12:07:11.542 [main] INFO  VMInfo - VMInfo# operatingSystem class =>
sun.management.OperatingSystemImpl
2020-06-28 12:07:11.563 [main] INFO  Engine - the machine info  =>

    osInfo: Private Build 1.8 25.252-b09
    jvmInfo:      Linux amd64 5.3.0-59-generic
    cpu num:      1

    totalPhysicalMemory:    -0.00G
    freePhysicalMemory:     -0.00G
    maxFileDescriptorCount: -1
    currentOpenFileDescriptorCount: -1

    GC Names      [Copy, MarkSweepCompact]

size  MEMORY_NAME          | allocation_size          | init_
6MB   Eden Space           | 273.06MB                 | 273.0
      Code Cache           | 240.00MB                 | 2.44M
```

查看运行结果


```
2020-06-28 12:07:23.191 [job-0] INFO  JobContainer - PerfTrace not enable!
2020-06-28 12:07:23.204 [job-0] INFO  StandAloneJobContainerCommunicator - Total 104 records, 19738 bytes | Speed 1.93KB/s, 10 records/s | Error 0 records, 0 bytes | All Task WaitWriterTime 0.001s | All Task WaitReaderTime 0.261s | Percentage 100.00%
2020-06-28 12:07:23.205 [job-0] INFO  JobContainer -
任务启动时刻      : 2020-06-28 12:07:11
任务结束时刻      : 2020-06-28 12:07:23
任务总计耗时      :          11s
任务平均流量      :          1.93KB/s
记录写入速度      :          10rec/s
读出记录总数      :          104
读写失败总数      :           0

hadoop@yu-VirtualBox:~/datax/bin$
```

在 MySQL 数据库中查看 news 表内容

```
mysql> select * from news;
+-----+-----+-----+-----+-----+-----+
| title                                     | toutiao                  | newslink                  | ttlink                    |
+-----+-----+-----+-----+-----+-----+
| 心中最重要的位置                         |                          | https://www.toutiao.com/group/6842940743472906766/ | https://www.toutiao.com/c/user/token/MS4wLjABAAAiAce5qhH31TeuB3UdpFMV8u-uwY2LnoiQI10uZHqAt8/ |
```


作业流程



转换：去除重复



检查表是否存在

检查表是否存在

作业项名称: 检查表是否存在

数据库连接: test [编辑...] [新建...] [Wizard...]

模式名称: [浏览(B)...]

表名: news [浏览(B)...]

[?] Help [确定(O)] [取消(C)]

若不存在，创建文件

作业名称: 创建文件

文件名: news [浏览(B)...]

如果文件存在则创建失败: ☒

结果中添加文件名 ☐

[?] Help [确定(O)] [取消(C)]

若存在，输入

步骤名称: 表输入

数据库连接: news [编辑...] [新建...] [Wizard...]

SQL

获取SQL查询语句...

```
SELECT
  title
, newslink
, toutiao
, ttlink
FROM news
```

过滤空值

步骤名称: 过滤记录

发送true数据给步骤: 增加序列

发送false数据给步骤:

条件:

NOT

title = null (String)

去重

步骤名称

去除重复记录

设置

增加计数器到输出?

☐

计数器字段

重定向重复记录

☐

错误描述

用来比较的字段 (没有条目意味着: 比较现在完成了)

▼

字段名称

忽略大小写

1

toutiao

N

表输出

步骤名称

表输出

数据库连接

news

▼

编辑...

新建...

Wizard...

目标模式

▼

浏览(B)...

目标表

news1

▼

浏览(B)...

提交记录数量

1000

▼

前一步

▼

在 MySQL 创建 news1 表

```
mysql> create table news1(title varchar(100),newslink varchar(100),toutiao varchar(100),tllink varchar(100),valuenam varchar(5));
Query OK, 0 rows affected (0.02 sec)

mysql>
```


执行转换



执行结果

步骤名称	复制的记录行数	读	写	输入	输出
1 表输入	0	0	104	104	0
2 过滤记录	0	104	104	0	0
3 去除重复记录	0	104	102	0	0
4 表输出	0	102	102	0	102

执行作业



执行结果

历史 日志 作业度量 Metrics			
	注释	结果	原因
	开始执行任务		开始
	任务执行完毕	成功	
存在	开始执行任务		Followed无条件的链接
存在	任务执行完毕	成功	
	开始执行任务		Followed link after su
	任务执行完毕	成功	
	开始执行任务		Followed link after su
	任务执行完毕	成功	
	任务执行完毕	成功	完成

查看数据

ID	标题	URL	来源	URL
1	心中最重要的位置	https://www.toutiao.com/group/6842940743472906766/	新华社	https://www.toutiao.com/group/6842940743472906766/
2	真正做到为官一任，造福一方	https://www.toutiao.com/group/6842897032844149256/	求是网	https://www.toutiao.com/group/6842897032844149256/
3	超62.7万！俄罗斯单日新增新冠肺炎确诊病例6852例，累计627646例	https://www.toutiao.com/group/6842940743472906766/	环球网	https://www.toutiao.com/group/6842940743472906766/
4	阿尔特塔：我将尽力向球员解释，踢足总杯决赛是多么美妙的事	https://www.toutiao.com/group/6842897032844149256/	懂球帝	https://www.toutiao.com/group/6842897032844149256/
5	印度累计新冠病例数超过50万例	https://www.toutiao.com/group/6842931487927435789/	环球网	https://www.toutiao.com/group/6842931487927435789/
6	电讯报：曼城已经签下凯尔·沃克16岁青训天才	https://www.toutiao.com/group/6842784786017157646/	懂球帝	https://www.toutiao.com/group/6842784786017157646/

命令行界面显示

```
2020/06/28 15:30:27 - 表输出.0 - Connected to database [news] (commit=1000)
2020/06/28 15:30:27 - 表输入.0 - Finished reading query, closing connection.
2020/06/28 15:30:27 - 表输入.0 - 完成处理 (I=206, O=0, R=0, W=206, U=0, E=0)
2020/06/28 15:30:27 - 过滤记录.0 - 完成处理 (I=0, O=0, R=206, W=206, U=0, E=0)
2020/06/28 15:30:27 - 去除重复记录.0 - 完成处理 (I=0, O=0, R=206, W=171, U=0, E=0)
2020/06/28 15:30:27 - 表输出.0 - 完成处理 (I=0, O=171, R=171, W=171, U=0, E=0)
2020/06/28 15:30:27 - news - 开始项[成功]
2020/06/28 15:30:27 - news - 完成作业项[成功] (结果=[true])
2020/06/28 15:30:27 - news - 完成作业项[转换] (结果=[true])
2020/06/28 15:30:27 - news - 完成作业项[检查表是否存在] (结果=[true])
2020/06/28 15:30:27 - news - 任务执行完毕
2020/06/28 15:30:27 - Spoon - 任务已经结束.
Window.configureShell: images disposed
Window.configureShell: images disposed
```

四、实验结果分析和总结

这次实验设计并实现一个舆情热点采集系统。实验所需的技术在以前的实验中均有设计，难度并不大。但是这是第一次系统的、完整的完成数据采集清洗任务，更符合实际大数据应用的需求。实验要求使用爬虫技术从网络爬取数据，因为设计大量编程，较有难度，但翻阅书上例题，百度查询后得以解决。Datax抽取和 kettle 清洗技术都做过相关实验，这次实验巩固并提高了相应的知识和技术，使我能更加熟练的操作。但是仍有不足之处：使用 kettle 清洗数据只进行了简单的过滤和去重，更加复杂的操作并没有实现，需要更多的练习和加倍的努力。